

Задача классификации приступов эпилепсии

Вещев Егор Дмитриевич

Научный руководитель: д. ф.-м. н. Бережной Е. И.

Ярославский государственный университет им. П. Г. Демидова

июнь 2026 г.

- Эпилепсия — одно из самых распространённых неврологических заболеваний.
- Диагностика требует длительного анализа электроэнцефалограмм (ЭЭГ).
- Применение методов машинного обучения позволяет автоматизировать распознавание приступов.

- Эпилепсия — одно из самых распространённых неврологических заболеваний.
- Диагностика требует длительного анализа электроэнцефалограмм (ЭЭГ).
- Применение методов машинного обучения позволяет автоматизировать распознавание приступов.

Цель работы: построить и сравнить несколько моделей классификации на открытом датасете ЭЭГ BEED:

- Случайный лес (Random Forest)
- Градиентный бустинг (XGBoost)
- Многослойный перцептрон (MLP)

Задача классификации

- Классы ЭЭГ-активности (4 класса):
 - 1 Здоровые
 - 2 Генерализованные приступы
 - 3 Фокальные приступы
 - 4 Приступные события
- Метрика: accuracy (доля правильных ответов)

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- Функция потерь для нейросетей: кросс-энтропия

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c})$$

Недообучение и переобучение

Недообучение (underfitting)

Модель слишком проста, не улавливает закономерности. Плохая точность на всех выборках.

Переобучение (overfitting)

Модель запоминает шум, сложна для данных. Высокая точность на обучении, низкая на тесте.


Недообучение и переобучение

Недообучение (underfitting)

Модель слишком проста, не улавливает закономерности. Плохая точность на всех выборках.

Переобучение (overfitting)

Модель запоминает шум, сложна для данных. Высокая точность на обучении, низкая на тесте.



Кривые обучения (train/val loss) для MLP — нет расхождения.

Дерево решений и ансамбли

Дерево решений

Разбиение признаков, критерий Джини:

$$G = 1 - \sum_{k=1}^K p_k^2$$

Случайный лес (Random Forest)

Ансамбль деревьев, bagging, случайный выбор признаков.
Итоговый прогноз — голосование.

Градиентный бустинг (XGBoost)

Последовательное исправление ошибок:

$$F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$$

Многослойный перцептрон (MLP)

- Полносвязная сеть, 7 скрытых слоёв:
 $16 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow 4$
- Функции активации: ReLU и GELU

Многослойный перцептрон (MLP)

- Полносвязная сеть, 7 скрытых слоёв:
 $16 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow 4$
- Функции активации: ReLU и GELU

Регуляризация

- Batch Normalization: $\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$, $y_i = \gamma \hat{x}_i + \beta$
- Dropout (вероятность 0.5)
- SGD с моментом:
$$v_{t+1} = \mu v_t - \eta \nabla L(w_t), \quad w_{t+1} = w_t + v_{t+1}$$

Датасет BEED

- Bangalore EEG Epilepsy Dataset (UCI)
- 8000 записей, 16 каналов ЭЭГ
- 4 класса по 2000 образцов (сбалансирован)
- Табличный вид (CSV) — временная структура отсутствует

Датасет BEED

- Bangalore EEG Epilepsy Dataset (UCI)
- 8000 записей, 16 каналов ЭЭГ
- 4 класса по 2000 образцов (сбалансирован)
- Табличный вид (CSV) — временная структура отсутствует

Класс	Описание
0	Здоровые
1	Генерализованные приступы
2	Фокальные приступы
3	Приступные события

Экспериментальная часть: предобработка

- Нормализация признаков (StandardScaler)
- Разделение на тренировочную (60%), валидационную (20%) и тестовую (20%) выборки
- Стратификация по классам
- Кросс-валидация: StratifiedShuffleSplit (10 сплитов, test_size=30%)

Экспериментальная часть: предобработка

- Нормализация признаков (StandardScaler)
- Разделение на тренировочную (60%), валидационную (20%) и тестовую (20%) выборки
- Стратификация по классам
- Кросс-валидация: StratifiedShuffleSplit (10 сплитов, test_size=30%)

Гиперпараметры (подбор GridSearchCV):

- Random Forest: n_estimators=400, min_samples_leaf=1, min_samples_split=2
- XGBoost: n_estimators=500, learning_rate=0.1, max_depth=12, subsample=0.7

Результаты классических моделей

Таблица: Точность и время работы

Модель	Accuracy (test)	Время (с)
Random Forest	96.56%	19.4
XGBoost	97.31%	2.48

Результаты классических моделей

Таблица: Точность и время работы

Модель	Accuracy (test)	Время (с)
Random Forest	96.56%	19.4
XGBoost	97.31%	2.48

Вывод: XGBoost быстрее и точнее на данном датасете.

MLP: влияние глубины сети

Таблица: Сравнение разного числа скрытых слоёв

Число слоёв	Точность на тесте	Примечание
3	95.6%	Быстрое обучение
7	98.75%	Оптимальная глубина
15	82.4%	Переобучение

MLP: влияние глубины сети

Таблица: Сравнение разного числа скрытых слоёв

Число слоёв	Точность на тесте	Примечание
3	95.6%	Быстрое обучение
7	98.75%	Оптимальная глубина
15	82.4%	Переобучение

Вывод: Слишком глубокая сеть (15 слоёв) приводит к переобучению.

Анализ переобучения MLP




Рис. 1: График train/val loss

- Кривые синхронно снижаются
- Валидационная ошибка не растёт
- Стабильность при разных `random_state`: $98.7\% \pm 0.3\%$
- Нет переобучения

Пример ошибочной классификации MLP

Таблица: Образец, где модель ошиблась (истинный класс 2, предсказан 3)

Канал	Значение
X1	0.0405
X2	-0.0501
X3	0.2860
X4	0.2789
X5	0.0750
X6	-0.0190
X7	0.1210
X8	0.3683

Канал	Значение
X9	-0.1929
X10	0.3879
X11	0.5496
X12	0.4212
X13	-0.2841
X14	0.6526
X15	0.6720
X16	0.1980

- 1 Проведён анализ датасета BEED, выполнена предобработка.
- 2 Обучены и сравнены Random Forest (96.56%), XGBoost (97.31%) и MLP.
- 3 Подобрана оптимальная архитектура MLP (7 слоёв) — точность 98.75%.
- 4 Увеличение глубины до 15 слоёв приводит к переобучению (82.4%).
- 5 Модели не переобучены (графики loss, стабильность).

- 1 Проведён анализ датасета BEED, выполнена предобработка.
- 2 Обучены и сравнены Random Forest (96.56%), XGBoost (97.31%) и MLP.
- 3 Подобрана оптимальная архитектура MLP (7 слоёв) — точность 98.75%.
- 4 Увеличение глубины до 15 слоёв приводит к переобучению (82.4%).
- 5 Модели не переобучены (графики loss, стабильность).

Практическая значимость: автоматическая классификация ЭЭГ с высокой точностью для поддержки диагностики. GitHub-репозиторий с кодом

Спасибо за внимание!